

---

# ANT COLONY OPTIMIZATION: LONGEST PATH

---

PROFESSOR(A): GISELE LOBO PAPP

AUTOR: PEDRO NASCIMENTO COSTA

## 1 INTRODUÇÃO

O *Ant Colony Optimization* (ACO) é uma técnica probabilística para achar caminhos em grafos, em particular pode-se achar os caminhos mais longos ou mais curtos dependendo da implementação. A origem da técnica vem de colônias de formigas que movimentam de um ninho até um objetivo (comida, geralmente) e fazem uso de feromônios para indicarem um caminho até tal objetivo para demais formigas. Nesse trabalho, dado um grafo direcionado  $G(V, E)$  com um peso atribuído a cada uma das arestas, deseja-se achar o caminho simples de maior peso do vértice 1 ao vértice  $N$ , no qual  $N$  é o último vértice do grafo, que tem vértices nomeados de 1 a  $N$ .




Figura 1: Representação de um grafo, exemplo.

Nesse grafo, tem-se o resultado de 15 como o melhor, aqui formigas fariam 2 possíveis caminhos, do vértice 1 para o 3, com peso 12, ou do vértice 1 para o 2 e em seguida para o 3, com peso 15. Nesse exemplo, feromônio seria depositado em ambos os caminhos, proporcional ao peso total do caminho completo e o esperado seria uma convergência para o caminho de peso 15, visto que é o de maior peso.

## 2 DESENVOLVIMENTO

### 2.1 CONSIDERAÇÕES

O trabalho foi desenvolvido em python 3.7, fazendo uso de algumas bibliotecas disponíveis. Em particular:

1. sys: Uso do *argv*, para passar entradas no algoritmo pela linha de comando ao rodá-lo.
2. copy, a função de cópia profunda(*deepcopy()*).
3. random: tratamento de sorteios de números 'aleatórios'.
4. numpy: Uso de funções de escolha, em particular a função *choice*
5. matplotlib: plotagem dos gráficos aqui presentes.

Demais partes, presentes no algoritmo, foram implementadas, como a representação da grafo e da formiga e o algoritmo do ACO em si.

Para executar o código presente, deve-se rodar:

```
python3 main.py [1] [2] [3] [4] [5]
```

No qual:

1. Número de caminhamentos(qts vezes as formigas irão atravessar o grafo).
2. Número de formigas.
3. Taxa da evaporação(entre 0 e 1).
4. Caminho para o arquivo de entrada.
5. Número de vértices(None ou o número de vértices correspondentes com o arquivo de entrada)

**Observação:** O comando 'python3' pode ser diferente dependendo da configuração do Python na máquina na qual se executa o código, é importante conferir a versão previamente para executar o comando correto.

### 2.2 METODOLOGIA

O diagrama disponível abaixo, foi o seguido para realização do fluxo do trabalho:

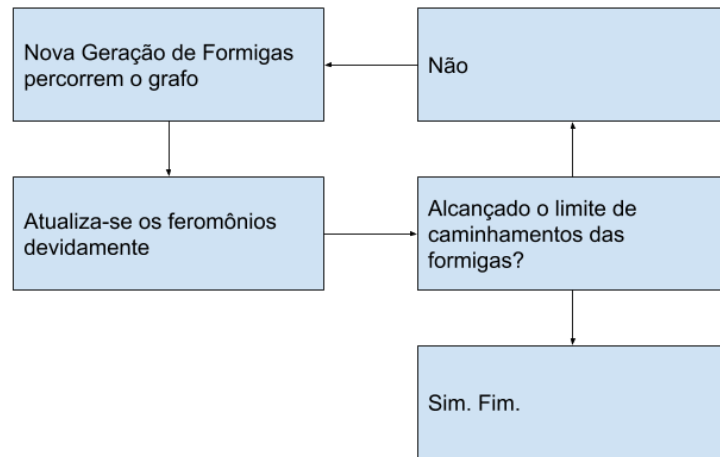


Figura 2: Diagrama, fluxo e estados.

### 2.2.1 FORMIGA

Um formiga é um objeto(classe) de tal forma que sua instância armazena algumas informações a respeito do caminho percorrido. Em particular sabe seu vértice atual no grafo, o caminho que já foi percorrido e o peso total do caminho que já percorreu.

O caminho é necessário se conhecer, porque através desse conhecimento individual de cada instância pode-se fazer a atualização dos feromônios.

O peso do caminho é nossa *fitness*, uma *fitness* boa influencia diretamente na quantidade de feromônio deixado pela formiga pelo caminho.

### 2.2.2 ACO

A implementação do *Ant Colony Optimization* segue o seguinte fluxo:

1. Inicia-se um caminhamento
2. Cria-se o número desejado de formigas e faz com que elas percorram o grafo.
3. As formigas que forem válidas (tiverem chegado no vértice desejado) são separadas.
4. Aplica-se a evaporação do feromônio e através das formigas válidas se faz a atualização do *feromônio*.
5. Repete a partir de um novo caminhamento. Caso tenha-se finalizado os caminhamentos, fim do fluxo.

### 2.2.3 FITNESS

A *fitness* é essencialmente o peso de um caminho, sua influência se da na escolha de uma aresta e do depósito de feromônio.

Para a atualização de feromônio foi usada a seguinte fórmula:  $((i) * (1 - ii) + iii) / (iv)$

- i Feromônio atual.
- ii Taxa de evaporação.
- iii Peso do caminho percorrido pela formiga.
- iv Peso total das arestas do grafo.

Para a escolha das arestas, foi-se atribuído um peso de acordo com a fórmula:  
 $((I) * (II)) / ((III) * (IV))$

- I Peso da aresta
- II Feromônio da aresta
- III Peso das possíveis arestas
- IV Feromônio das possíveis arestas

Em geral, arestas serão favorecidos ao fazerem parte de um caminho maior e ao terem maior peso. Buscando convergência para o melhor caminho possível.

#### 2.2.4 CRITÉRIO DE PARADA

O critério de parada adotado foi o de número de caminhamentos. Desse modo temos um diagrama completo de tudo que foi acontecendo ao longo do tempo.

### 2.3 EXPERIMENTOS

Nos experimentos, foram observadas algumas parâmetros, em particular:

1. Número de caminhamentos.
2. Número de formigas.
3. Taxa de evaporação.

Dados esses fatores, foi observado a influência nas tomadas de decisões para quais fatores mais afetam o desempenho.

*O teste padrão utilizado foi o de:*

**Número de vezes que as todas as formigas caminham (caminhamentos): 100**

**Número de formigas: 100**

**Taxa de evaporação: 0.2**

Os demais testes, são uma variação em cima disso, especificando as mudanças na legenda.

### 2.3.1 DETERMINADO OS PARÂMETROS IDEIAS

Foram feitos 20 testes (chamados de iteração nos gráficos, no eixo horizontal) com *seed* diferentes, para cada alteração abaixo, rodou-se esses 20 testes, sendo que foi-se alterando todos os possíveis parâmetros, com o objetivo de ver qual em média teria os melhores indivíduos com consistência.

Foram analisadas duas bases de dados disponibilizadas e então uma terceira com uma quantidade bem maior de dados, também disponibilizada, utilizando as melhores variações descobertas nas outras duas bases.

### 2.3.2 TESTES NA BASE 1 (GRAPH1.TXT)




Figura 3: Base 1, Usando o padrão




Figura 4: Base 1, 50 caminhamentos




Figura 5: Base 1, 500 caminhamentos




Figura 6: Base 1, 50 formigas




Figura 7: Base 1, 500 formigas




Figura 8: Base 1, Taxa de evaporação 0.5

Agrupando os dados dos gráficos, podemos resumi-los na tabela a seguir:

Caminhamentos	Número de Formigas	Taxa de evaporação	Média dos melhores caminhos encontrados
100	100	0.2	632.65
50	100	0.2	625.8
500	100	0.2	641.35
100	50	0.2	624
100	500	0.2	643
100	100	0.5	628.15

Figura 9: Base 1, Tabela resumida



2.3.3 TESTES NA BASE 2(GRAPH2.TXT)




Figura 10: Base 2, Usando o padrão




Figura 11: Base 2, 50 caminhamentos




Figura 12: Base 2, 500 caminhamentos




Figura 13: Base 2, 50 formigas




Figura 14: Base 2, 500 formigas




Figura 15: Base 2, Taxa de evaporação 0.5

Agrupando os dados dos gráficos, podemos resumi-los na tabela a seguir:

Caminhamentos	Número de Formigas	Taxa de evaporação	Média dos melhores caminhos encontrados
100	100	0.2	131.35
50	100	0.2	130.35
500	100	0.2	139.85
100	50	0.2	131.55
100	500	0.2	138.15
100	100	0.5	134

Figura 16: Base 2, Tabela resumida

#### 2.3.4 TESTE NA BASE 3(GRAPH3.TXT)

Dado as informações disponíveis ao analisar os grafos acima das Base 1 e 2, olhamos para principalmente os melhores caminhos, podemos observar que dado isso, os parâmetros que mostraram melhorias foram os de número de caminhamentos e quantidade de formigas.

Nos casos de aumento da taxa de evaporação, há uma dificuldade em se convergir para indivíduos melhores, portanto em média os melhores indivíduos são piores do que quando se varia outros parâmetros. Por outro lado, porém, a taxa mais baixa tende a levar a uma conversão para um caminho mais rápida, não necessariamente no melhor caminho possível.




Figura 17: Base 3, 50 caminhamentos e 50 formigas




Figura 18: Base 3, 100 caminhamentos e 100 formigas




Figura 19: Base 3, 500 caminhamentos e 500 formigas

Agrupando os dados dos gráficos, podemos resumi-los na tabela a seguir:

<b>Caminhamentos</b>	<b>Número de Formigas</b>	<b>Taxa de evaporação</b>	<b>Média dos melhores caminhos encontrados</b>
50	50	0.2	5168.75
100	100	0.2	6052
500	500	0.2	6648

Figura 20: Base 3, Tabela resumida

Os experimentos realizados, comparam as melhores variações de parâmetros encontradas testando anteriormente. O fator "melhor" deles vem de possuírem uma média melhor do melhor caminho.

Alguns fatores interessantes, são o aumento no número de formigas, que acarreta no aumento da exploração, porém, isso também influencia numa maior chance de se acabar com caminhos inviáveis, tendo que se descartar formigas, principalmente no início, quando se tem nenhum feromônio para influenciar a convergência.

Outro fator de interesse, é a rápida convergência ao se aproximar cada vez mais a taxa de evaporação de números menores, pois caminhos com mais feromônios serão mantidos como tal por um número maior de caminhamentos seguintes, entretanto ao custo de se convergir rápido demais em alguns casos de máximo local, levando a pouca exploração.

### 3 CONCLUSÃO

Executando os testes, foi-se concluindo a teoria vista nas aulas, o modelo implementado apresenta diversos fatores que refletem o esperado, uma taxa de evaporação muita alta leva a uma difícil convergência, por exemplo.

Além disso, a técnica do *Ant Colony Optimization* se mostrou valiosa na solução do problema, pois leva a respostas próximas da melhor solução do problema, quando se trata achar caminhos em grafos, em particular com uma certa escalabilidade.

No mais, a importância de se testar de maneira progressiva, fazendo pequenos ajustes foi importante, foram necessárias várias execuções para se constatar e observar os devidos comportamentos dos parâmetros. Assim como as diferentes *seeds* se mostraram com um valor impactante, afinal como pode-se observar nos gráficos, *seeds* diferentes podem possuir resultados distantes uns dos outros.

## REFERÊNCIAS

- Slides aulas de Computação Natural disponíveis no moodle.
- Referências explicativas sobre o *ACO* <https://bit.ly/2DIRV55>